



PREDIZIONE RITARDO VOLI

CHRIS BERRY N'DRY
ANDREA SILVESTRO
GIULIA ALLEGRI

PROBLEMA

ANALIZZIAMO UN DATASET DI 10.000 VOLI DI LINEA, CARATTERIZZATO DA **35 VARIABILI**.
L'OBIETTIVO È RISOLVERE IL PROBLEMA DELL'INCERTEZZA OPERATIVA. PREVEDENDO SE UN VOLO SUBIRÀ **UN RITARDO SUPERIORE DI 15 MINUTI**



df.head(10)												
✓ 0.0s												Python
	year	month	day_of_month	day_of_week	fl_date	op_unique_carrier	op_carrier_fl_num	origin	origin_city_name	origin_state_nm	dest	dest_city_name
0	2024	4	18	4	2024-04-18	MQ	3535.0	DFW	Dallas/Fort Worth, TX	Texas	RAP	Rapid City,
1	2024	1	1	1	2024-01-01	AA	148.0	CLT	Charlotte, NC	North Carolina	PHX	Phoenix,
2	2024	12	12	4	2024-12-12	9E	5440.0	CHA	Chattanooga, TN	Tennessee	ATL	Atlanta,
3	2024	4	8	1	2024-04-08	WN	1971.0	OMA	Omaha, NE	Nebraska	LAS	Las Vegas,
4	2024	2	16	5	2024-02-16	WN	862.0	BWI	Baltimore, MD	Maryland	MYR	Myrtle Beach,
5	2024	4	15	1	2024-04-15	WN	2358.0	SAN	San Diego, CA	California	PHX	Phoenix,
6	2024	11	27	3	2024-11-27	G4	163.0	MLB	Melbourne, FL	Florida	ABE	Allentown/Bethlehem/Eas
7	2024	8	31	6	2024-08-31	AS	1269.0	BNA	Nashville, TN	Tennessee	PDX	Portland,
8	2024	4	19	5	2024-04-19	OO	3438.0	LAX	Los Angeles, CA	California	SJC	San Jose,
9	2024	2	8	4	2024-02-08	OO	5654.0	SFO	San Francisco, CA	California	BFL	Bakersfield,

PULIZIA E EDA



--- REPORT DIAGNOSTICO ---

Voli totali nel file: 10000

Voli cancellati: 122

Voli dirottati: 42

Conteggio valori nulli per colonna (le più critiche):

ora_part_reale	116
ritardo_partenza	116
tempo_rullaggio_uscita	120
ora_decollo	120
ora_atterraggio	127
tempo_rullaggio_entrata	127
ora_arr_reale	127
ritardo_arrivo	164
codice_cancellazione	9878
durata_reale	164
minuti_volo_effettivi	164
dtype:	int64

Righe prima: 10000

Righe dopo: 9836

Rimossi: 164 voli (cancellati + dirottati)

01 **ANALISI ESPLORATIVA DEL DATASET PER VALUTARE LE VARIABILI**

02 **RIMOZIONE DI 164 VOLI CANCELLATI E DIROTTATI, RIDUCENDO IL DATASET DA 10000 A 9836 RIGHE.**

03 **ELIMINAZIONE DI COLONNE RIDONDANTI E A ZERO VARIANZA, DA 35 COLONNE A 26 COLONNE UTILI PER L'ANALISI.**



FEATURE ENGINEERING



01 OTTIMIZZIAMO VARIABILI PRE-
ESISTENTI PER ALLEGGERIRE IL
DATASET

02 UNIAMO LE VARIABILI RIGUARDATI GLI
AREOPORTI DI ARRIVO E DESTINAZIONE

03 GENERIAMO LA NUOVA VARIABILE
ROTTA

rotta	ora_part_prevista	\
DFW-RAP	1018	
CLT-PHX	1637	
CHA-ATL	1000	
OMA-LAS	1330	
BWI-MYR	1340	
SAN-PHX	715	
MLB-ABE	933	
BNA-PDX	1855	
LAX-SJC	820	
SFO-BFL	2235	



FEATURE ENGINEERING

```
# rotta: combina aeroporto di origine e destinazione
df['rotta'] = df['aeroporto_orig_cod'] + '-' + df['aeroporto_dest_cod']

# ora di partenza: da formato HMMH (es. 1547) estraiamo solo l'ora (15)
df['ora_partenza'] = df['ora_part_prevista'] // 100

# fascia oraria basata sull'ora di partenza
def fascia_oraria(ora):
    if 5 <= ora < 12:
        return 'mattina'
    elif 12 <= ora < 18:
        return 'pomeriggio'
    elif 18 <= ora < 22:
        return 'sera'
    else:
        return 'notte'

df['fascia_partenza'] = df['ora_partenza'].apply(fascia_oraria)

# verifica
print(df[['aeroporto_orig_cod', 'aeroporto_dest_cod', 'rotta', 'ora_part_prevista', 'ora_partenza', 'fascia_partenza']].head(10))
```



01 PRENDIAMO LE VARIABILI RIGUARDANTI
GLI ORARI DI PARTENZA

DEFINIAMO 4 CATEGORIE TEMPORALI

02

GENERIAMO UNA VARIABILE PER
FASCE ORARIE

03

	ora_partenza	fascia_partenza
0	10	mattina
1	16	pomeriggio
2	10	mattina
3	13	pomeriggio
4	13	pomeriggio
5	7	mattina
6	9	mattina
7	18	sera
8	8	mattina
9	22	notte



FEATURE ENGINEERING



	media_meteo_orig	media_ritardo_compagnia	media_traffico_orig	\
0	2.626168	2.929825	2.546729	
1	0.952229	6.933824	3.162420	
2	7.133333	5.632353	2.800000	
3	1.100000	3.178123	6.600000	
4	0.014815	3.178123	1.925926	
5	0.105634	3.178123	3.401408	
6	0.000000	5.817647	0.000000	
7	0.153846	2.584127	4.814103	
8	0.312950	7.815370	2.751799	
9	3.967568	7.815370	2.362162	

	media_sicurezza_orig	media_ritardo_prec	media_durata_rotta
0	0.0	4.393333	117.666667
1	0.0	14.450226	244.142857
2	0.0	3.444444	28.142857
3	0.0	7.244356	158.000000
4	0.0	7.244356	69.500000
5	0.0	1.659781	52.285714
6	0.0	0.750000	137.000000
7	0.0	7.253968	262.500000
8	0.0	1.803922	48.714286
9	0.0	0.000000	40.000000

01 SELEZIONE E ISOLAMENTO DI **VARIABILI FUTURE**

02 OTTIMIZIAMO IL LORO UTILIZZO CREANDO **MEDIE STORICHE** DA POTER UTILIZZARE PER ADDESTRARE IL MODELLO

03 GENERAZIONE DELLE **VARIE MEDIE STORICHE** SOTTO FORMA TABULARE



RAFFINAMENTO DEL DATASET

```
# Lista delle colonne "del futuro" o non più utili
cols_da_eliminare = [
    'ritardo_partenza', 'ritardo_arrivo', 'ritardo_vettore', 'ritardo_meteo',
    'ritardo_traffico_aereo', 'ritardo_sicurezza', 'ritardo_aereo_precedente',
    'ora_part_reale', 'ora_arr_reale', 'durata_reale', 'minuti_volo_effettivi',
    'ora_decollo', 'ora_atterraggio', 'tempo_rullaggio_uscita', 'tempo_rullaggio_entrata'
]

df.drop(columns=cols_da_eliminare, inplace=True)

print(f"Pulizia completata. Colonne rimaste per il modello: {len(df.columns)}")
df.head(10)
```

✓ 0.0s Open 'df' in Data Wrangler

Pulizia completata. Colonne rimaste per il modello: 21

01 ELIMINAZIONE DELLE VARIABILI "DEL FUTURO" (DATA LEAKAGE)

PER ADDESTRARE UN MODELLO PREDITTIVO REALISTICO, POSSIAMO USARE SOLO INFORMAZIONI NOTE PRIMA DEL DECOLLO. ABBIAMO RIMOSSO TUTTE LE COLONNE GENERATE DOPO L'EVENTO

```
# Lista delle colonne da rimuovere per evitare ridondanza
cols_da_rimuovere = [
    'aeroporto_orig_cod',
    'aeroporto_dest_cod',
    'ora_part_prevista',
    'ora_arr_prevista',
    'ora_partenza',
    'data_volo'
]

# Eseguiamo la rimozione
df.drop(columns=cols_da_rimuovere, inplace=True)

print(f"Colonne rimaste ({len(df.columns)}): {df.columns.tolist()}")
df.head(10)
```

✓ 0.0s Open 'df' in Data Wrangler

Colonne rimaste (15): ['mese', 'giorno_mese', 'giorno_settimana', 'compagnia', 'durata_prevista', 'distanza', 'rotta', 'fascia_partenza', 'media_meteo_orig', 'media_rita

02 RIMOZIONE DELLA RIDONDANZA E DIMENSIONALITÀ:

ABBIAMO SNELLITO IL DATASET ELIMINANDO I DATI DUPLICATI O GIÀ RAPPRESENTATI IN ALTRE FORME PIÙ EFFICIENTI



DEFINIZIONE DEL TARGET

0 = IN ORARIO
1 = IN RITARDO

```
# Prima rimuoviamo le righe senza ritardo_arrivo registrato
df.dropna(subset=['ritardo_arrivo'], inplace=True)

# Poi creiamo il target (0 o 1)
df['in_ritardo'] = (df['ritardo_arrivo'] > 15).astype(int)

print(f"Righe rimaste: {len(df)}")
print(f"Voli in ritardo: {df['in_ritardo'].sum()}")
print(f"Percentuale: {df['in_ritardo'].mean():.1%}")
```

✓ 0.0s

ABBIAMO DEFINITO COME
VARIABILE **TARGET**
(IN_RITARDO) OGNI VOLO
CON UN RITARDO
SUPERIORE AI 15 MINUTI.

Righe rimaste: 9836
Voli in ritardo: 2040
Percentuale: 20.7%

**IL DATASET È SBILANCIATO,
CON UNA PERCENTUALE DI
RITARDI DEL 20,7%**

DRIVER DEI RITARDI: COSA INFLUENZA LA PUNTUALITÀ?



01

ESISTE UNA STAGIONALITÀ NEI RITARDI E QUALI SONO I GIORNI PIÙ CRITICI PER VIAGGIARE?

02

LA SCELTA DELLA COMPAGNIA INFLUISCE DRASTICAMENTE SULLA PROBABILITÀ DI ARRIVARE IN ORARIO?

03

I VOLI PIÙ LUNGHY SONO PIÙ SOGGETTI A RITARDI RISPETTO AI VOLI A CORTO RAGGIO?


CONCLUSIONI:

DALL'ANALISI ESPLORATIVA EMERGE CHE IL "RITARDO" SI VERIFICA TIPICAMENTE:


QUANDO: NEI MESI ESTIVI O DI GIOVEDÌ/VENERDÌ/DOMENICA

CHI: VOLANDO CON COMPAGNIE LOW-COST SPECIFICHE.

DOVE: SU TRATTE DI MEDIA-LUNGA PERCORRENZA.



VALIDAZIONE DELLE FEATURE



ANALISI FASCIA ORARIA

- **TREND:** LA PROBABILITÀ DI RITARDO CRESCE PROGRESSIVAMENTE DURANTE LA GIORNATA, TOCCANDO IL PICCO NELLE FASCE SERALI.
- **EFFETTO CASCATA:** I RITARDI MATTUTINI SI ACCUMULANO CREANDO UN EFFETTO DOMINO SUI VOLI SUCCESSIVI.
- **INSIGHT:** L'ORARIO DI PARTENZA È UN FATTORE CRITICO PER LA PREVISIONE DELLA PUNTUALITÀ.

	media_meteo_orig	media_ritardo_compagnia	media_traffico_orig	\
in_ritardo				
0	1.038468	4.904872	2.987406	
1	1.340739	5.132656	3.422150	
	media_sicurezza_orig	media_ritardo_prec	media_durata_rotta	
in_ritardo				
0	0.008703	5.826561	114.463524	
1	0.009879	7.842220	119.198218	

VALIDAZIONE SEGNALI PREDITTIVI

- **CONFRONTO MEDIE:** I VOLI IN RITARDO MOSTRANO VALORI STORICI PIÙ ALTI RISPETTO AI VOLI PUNTUALI.
- **EVIDENZA:** IL RITARDO DEL VOLO PRECEDENTE (MEDIA_RITARDO_PREC) È IL SEGNALE PIÙ FORTE (~7.8 VS ~5.8).
- **CONCLUSIONE:** LE VARIABILI STORICHE SONO PREDITTORI AFFIDABILI POICHÉ RIFLETTONO LA PERSISTENZA DEI DISSERVIZI.



ENCODING

ABBIAMO UTILIZZATO IL **LABELENCODER** PER **CONVERTIRE LE VARIABILI TESTUALI IN VALORI NUMERICI**, RENDENDOLE LEGGIBILI DAGLI ALGORITMI. QUESTA TRASFORMAZIONE È ESSENZIALE PER PERMETTERE AI MODELLI DI PROCESSARE CATEGORIE COME COMPAGNIE E ROTTE.

```
# Trasformiamo le colonne di testo in numeri
df['compagnia_n'] = le.fit_transform(df['compagnia'])
df['rotta_n']      = le.fit_transform(df['rotta'])
df['fascia_n']     = le.fit_transform(df['fascia_partenza'])

# Ora possiamo eliminare le colonne di testo originali
df.drop(columns=['compagnia', 'rotta', 'fascia_partenza'], inplace=True)

df.head()
```

✓ 1.1s

compagnia_n	rotta_n	fascia_n
8	1092	0
1	661	2
0	532	0
13	2449	2
13	498	2



TRAIN/TEST SPLIT E SCALING

```
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler

# 1. Divisione in Train (80%) e Test (20%)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# 2. Scaling delle feature
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

print(f"Dataset diviso: {X_train.shape[0]} campioni di train, {X_test.shape[0]} di test.")
```

Dataset diviso: 7868 campioni di train, 1968 di test.

ABBIAMO SUDDIVISO IL DATASET IN **TRAIN (80%)** E **TEST (20%)** PRIMA DI PROCEDERE CON LO **SCALING DELLE FEATURE**. QUESTA **SEQUENZA È FONDAMENTALE PER EVITARE IL DATA LEAKAGE**: IL MODELLO DEVE APPRENDERE I PARAMETRI DI **NORMALIZZAZIONE ESCLUSIVAMENTE DAI DATI DI ADDESTRAMENTO**.



MODELLAZIONE E PERFORMANCE A CONFRONTO

01 MODELLI UTILIZZATI:

- **LOGISTIC REGRESSION:** MODELLO LINEARE, SEMPLICE DA INTERPRETARE.
- **RANDOM FOREST:** INSIEME DI 100 ALBERI DECISIONALI, CAPACE DI CATTURARE RELAZIONI PIÙ COMPLESSE.

02 ACCURATEZZA (ACCURACY):

IL RANDOM FOREST OFFRE UNA PRECISIONE DECISAMENTE SUPERIORE (+16%), DIMOSTRANDOSI PIÙ ADATTO A GESTIRE LA COMPLESSITÀ DEI DATI AEROPORTUALI.

Accuratezza Logistic Regression: 61.79%

Accuratezza Random Forest: 78.30%


ANALISI CRITICA DEI RISULTATI (MATRICI DI CONFUSIONE)

NONOSTANTE L'ACCURATEZZA ELEVATA DEL RANDOM FOREST, L'ANALISI DELLE MATRICI DI CONFUSIONE RIVELA UNA SFIDA COMUNE NEI DATI REALI.



ENTRAMBI I
MODELLI FATICANO
A IDENTIFICARE
CORRETTAMENTE I
VOLI IN RITARDO


LA LOGISTIC REGRESSION, PUR MENO PRECISA GLOBALMENTE, È PIÙ BILANCIATA NEL TENTARE DI INDOVINARE I RITARDI (238 INDIVIDUATI).



IL RANDOM FOREST TENDE A ESSERE "CONSERVATIVO": CLASSIFICA QUASI TUTTO COME PUNTUALE (1526 CORRETTI), MA SBAGLIA LA MAGGIOR PARTE DEI RITARDI (393 MANCATI).

INTERPRETAZIONE DEL MODELLO:

FEATURE IMPORTANCE



I FATTORI DETERMINANTI:

- 01

LA ROTTA E IL TEMPO SONO I PREDITTORI PIÙ FORTI. QUESTO SUGGERISCE CHE IL RITARDO È STRETTAMENTE LEGATO ALLA SPECIFICA TRATTA AEREA E ALLA CONGESTIONE TIPICA DI CERTI GIORNI DEL MESE.
- 02

LA DURATA PREVISTA E LA DISTANZA GEOGRAFICA GIOCANO UN RUOLO CRUCIALE. I VOLI PIÙ LUNGI O CON TEMPI DI PERCORRENZA VARIABILI SONO PIÙ DIFFICILI DA GESTIRE PUNTUALMENTE.
- 03

IL CONTESTO TEMPORALE (MESE): CONFERMA QUANTO VISTO NELL'ANALISI ESPLORATIVA: LA STAGIONALITÀ È UN FATTORE CHIAVE PER IL MODELLO.

I SEGNALI SECONDARI:

- 01

METEO E TRAFFICO (MEDIA_METEO_ORIG, MEDIA_TRAFFICO_ORIG): SEBBENE IMPORTANTI, PESANO MENO DELLA ROTTA STESSA. IL MODELLO DÀ PIÙ IMPORTANZA ALLA "STORIA" DELLA TRATTA CHE ALLA SINGOLA CONDIZIONE METEOROLOGICA MEDIA.
- 02

COMPAGNIA E FASCIA ORARIA: SORPRENDENTEMENTE, COMPAIONO IN FONDO ALLA CLASSIFICA. QUESTO INDICA CHE, UNA VOLTA NOTA LA ROTTA E IL GIORNO, LA SPECIFICA COMPAGNIA AEREA INCIDE MENO SULLA PREVISIONE FINALE RISPETTO ALLE VARIABILI LOGISTICHE.

CONCLUSIONI:

"IL RITARDO NON È UN EVENTO CASUALE, MA UN FENOMENO GUIDATO PRINCIPALMENTE DALLA LOGISTICA DELLA ROTTA E DALLA PIANIFICAZIONE TEMPORALE. IL MODELLO HA DATO PRIORITÀ ALLA STRUTTURA DEL VIAGGIO PIUTTOSTO CHE A FATTORI ESTERNI VARIABILI COME IL NOME DELLA COMPAGNIA."

GRAZIE



PER L'ATTENZIONE

